Universidade Federal do Piauí
Laboratório de Inteligência Artificial - LINA

Introdução à Deep Learning

Bruno Vicente Alves de Lima

Introdução à Redes Neurais Artificiais

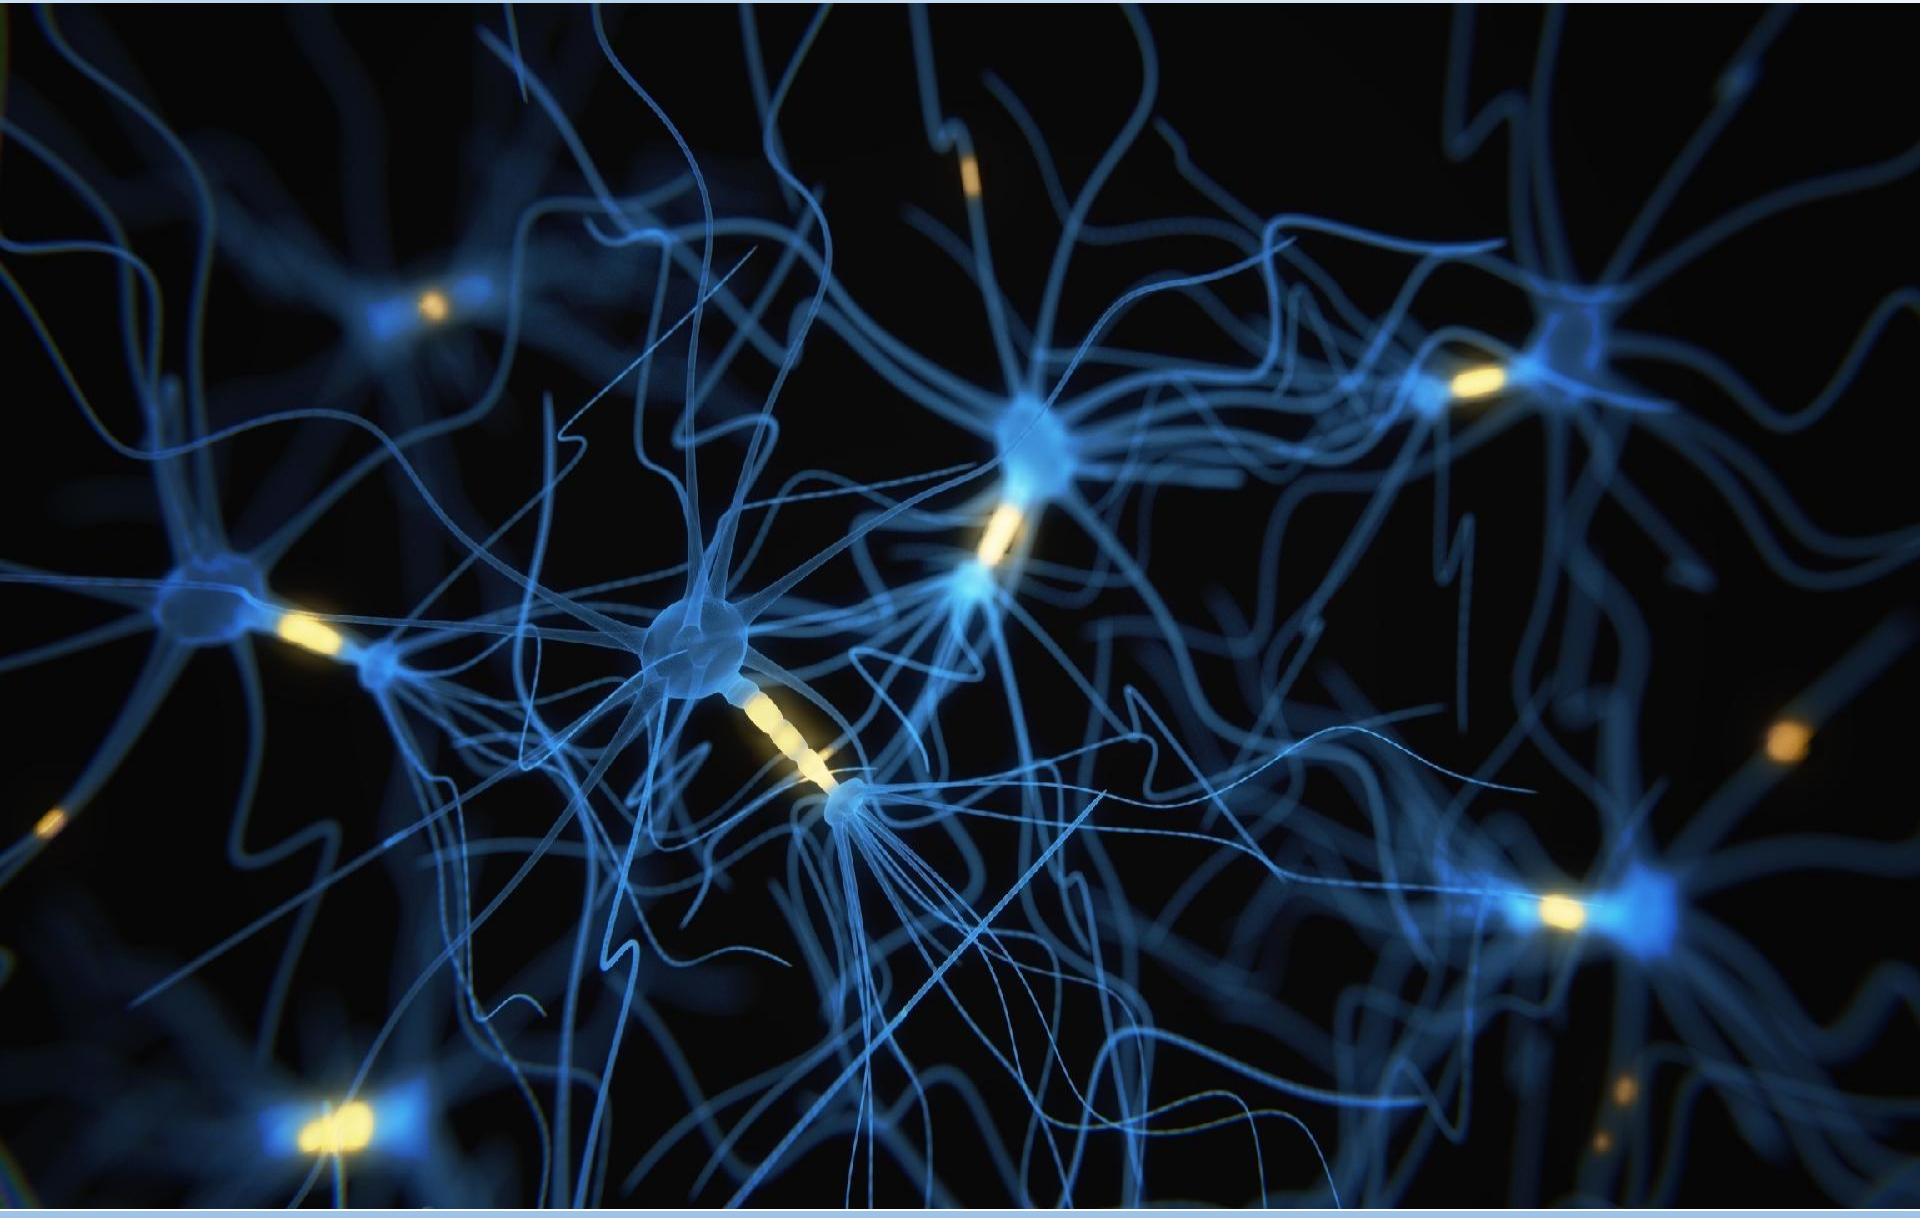

Introdução à Redes Neurais Artificiais

Redes Neurais Artificiais são técnicas computacionais que apresentam um modelo matemático inspirado na estrutura neural de organismos inteligentes e que adquirem conhecimento através da experiência.

Contexto Histórico

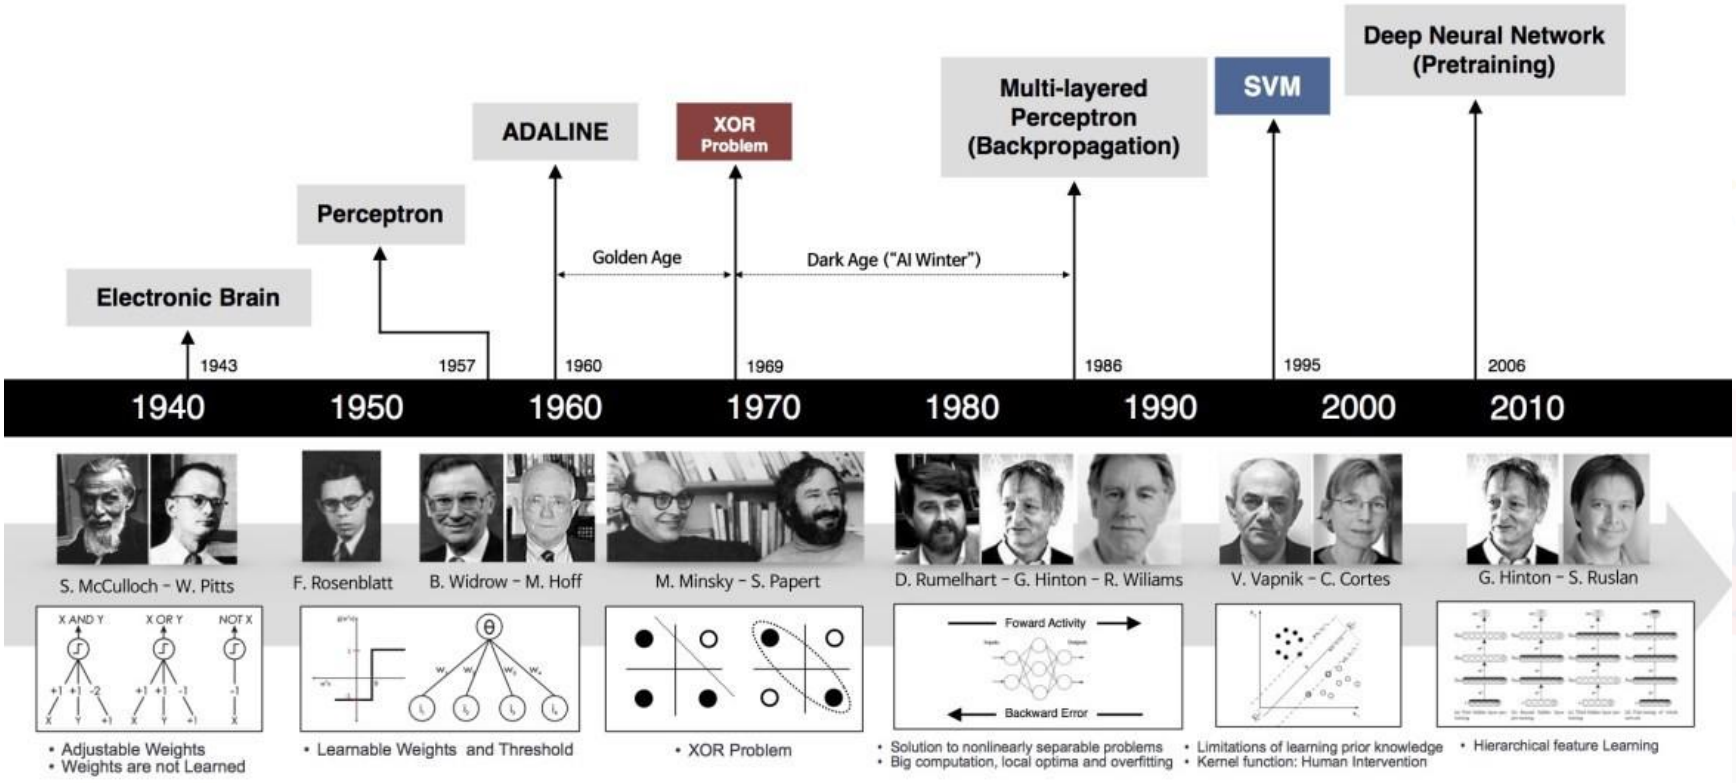

Neurônio Biológico

- Compõe o cérebro para processar informações;
- **Dentritos** – Recebem substâncias químicas que controlam o potencial elétrico na célula;
- **Axônios –** Transmite o impulso elétrico de um neurônio para o outro;
- **Sinapses** – Ponto de conexão entre um neurônio e outro. Regula a intensidade do impulso elétrico.

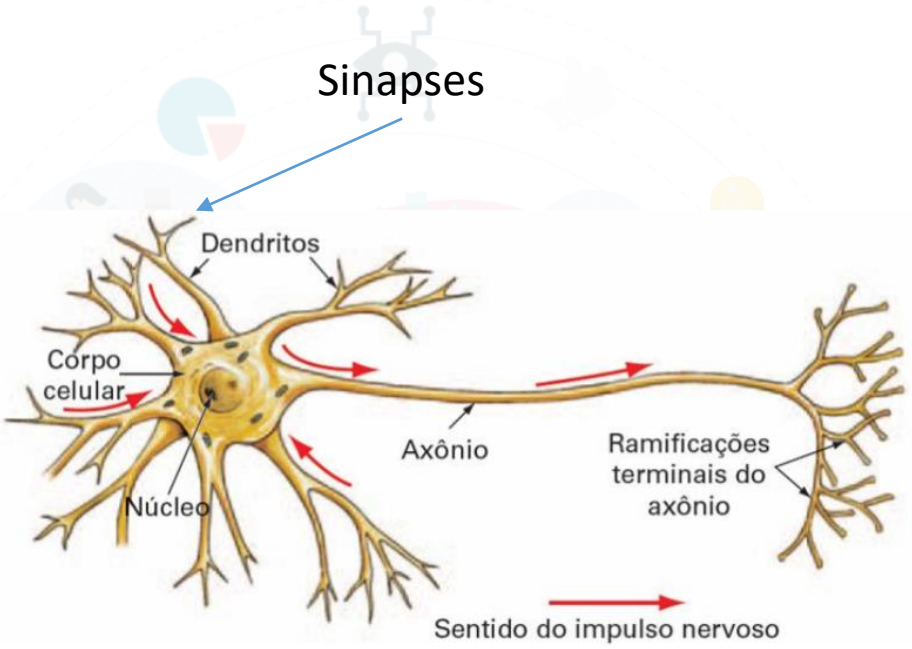

Neurônio Biológico

- Rede Neural Biológica

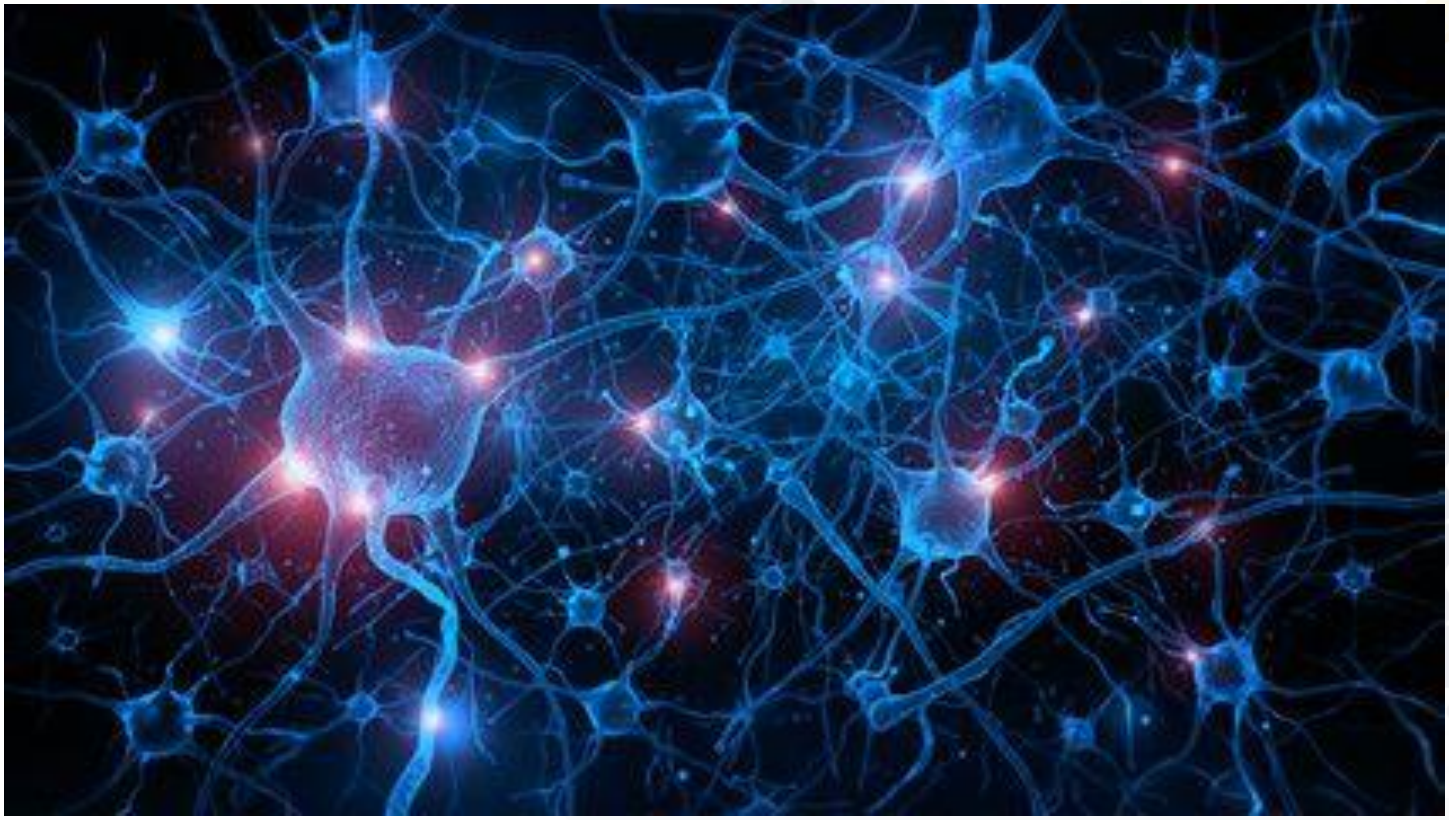

Neurônio Artificial - Perceptron

- Desenvolvido inicialmente por McCulloch e Pitts em 1943;
- Frank Rosenblatt criou Perceptron em 1658;
- Base das redes neurais artificiais.

Neurônio Artificial - Perceptron

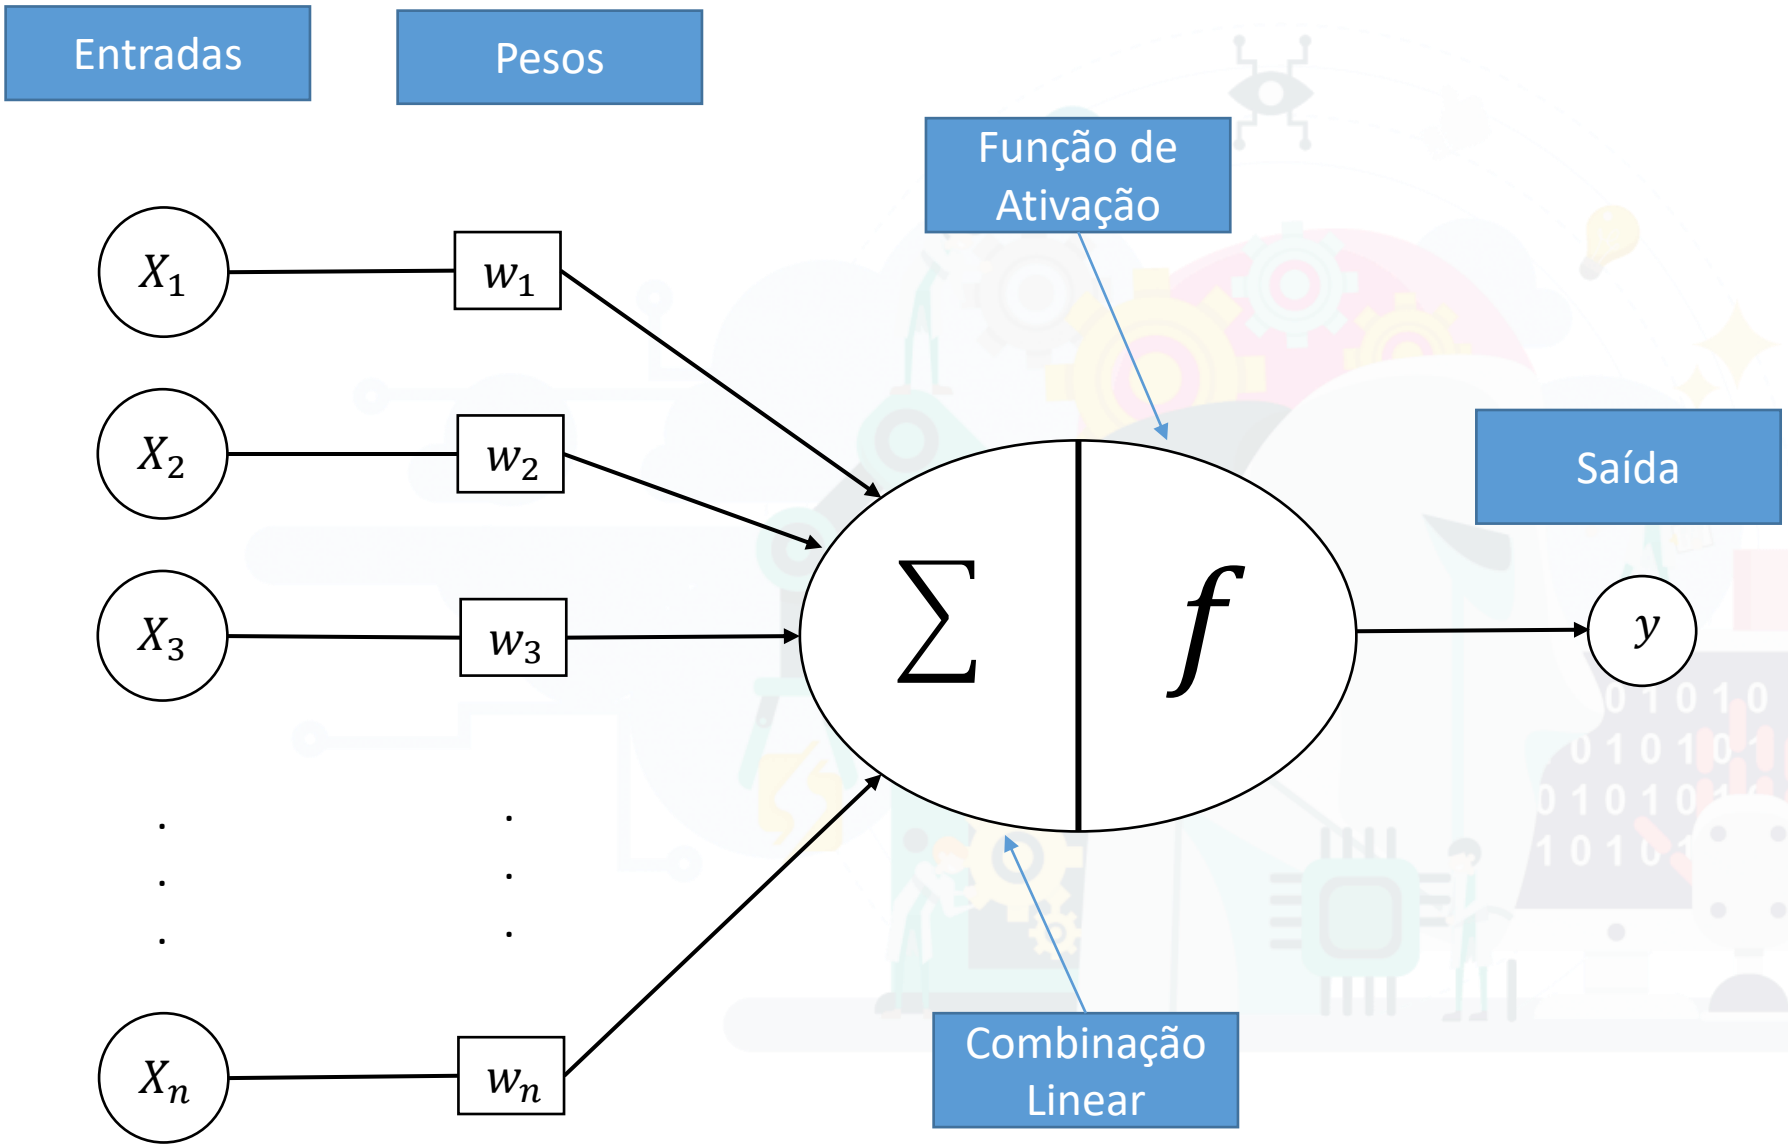

Neurônio Artificial x Neurônio Biológico

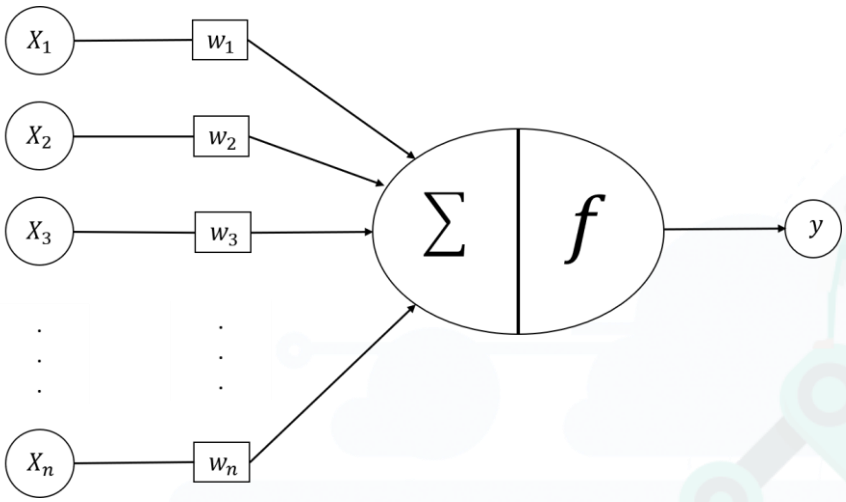

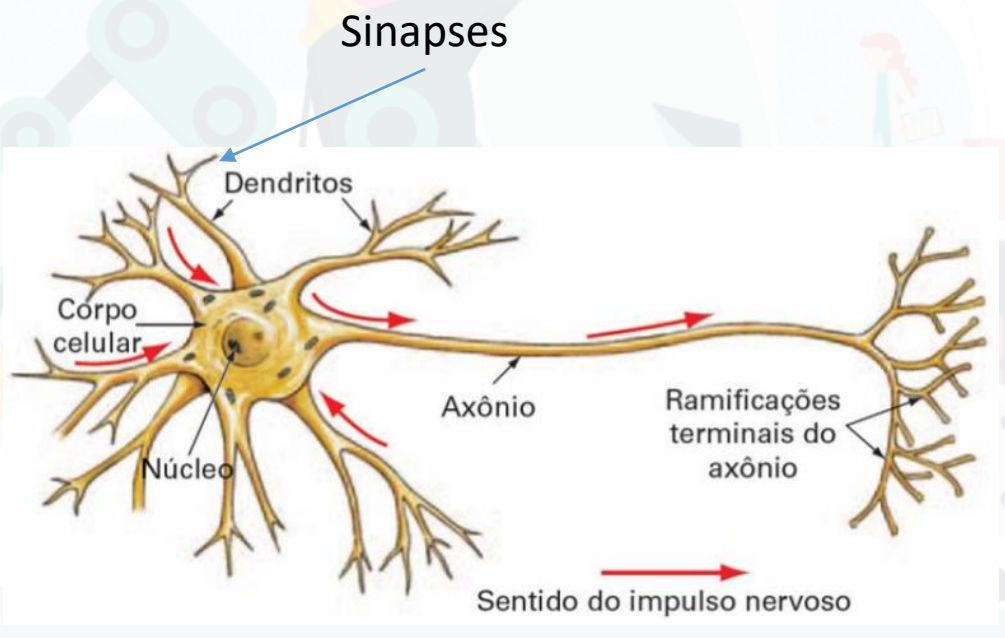

Neurônio Artificial - Perceptron

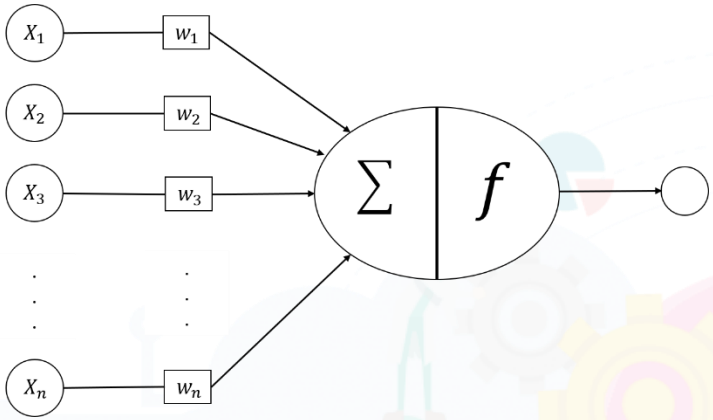

$$\sum_{i=1}^{n} x_i . w_i$$

$$x_1 w_1 + x_2 w_2 + x_3 w_3 + \ldots + x_n w_n = x^T . w$$

$$y = f(x^T . w) \quad \text{ou} \quad y = f(x . w^T)$$

Neurônio Artificial - Perceptron

- Entradas:
  - $x_1 = 2$,
  - $x_2 = 3$
  - $x_3 = 2.5$

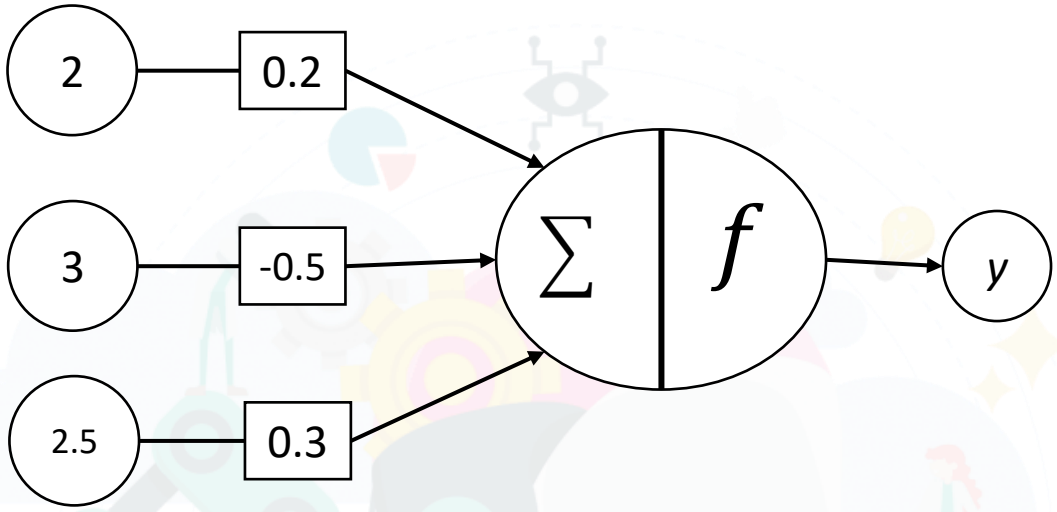

- Pesos:
  - $w_1 = 0.2$
  - $w_2 = -0.5$
  - $w_3 = 0.3$

$$f(x_1 w_1 + x_2 w_2 + x_3 w_3)$$

$$f(2 * 0.2 + 3 * (-0.5) + 2.5 * 0.3)$$

$$f(0.4 + (-1.5) + 2{,}8)$$

$$f(1{,}7) = 1$$

- Função de Ativação

$$f(x) = \begin{cases} 0, x < 1 \\ 1, x \geq 1 \end{cases}$$

Rede Neural Artificial

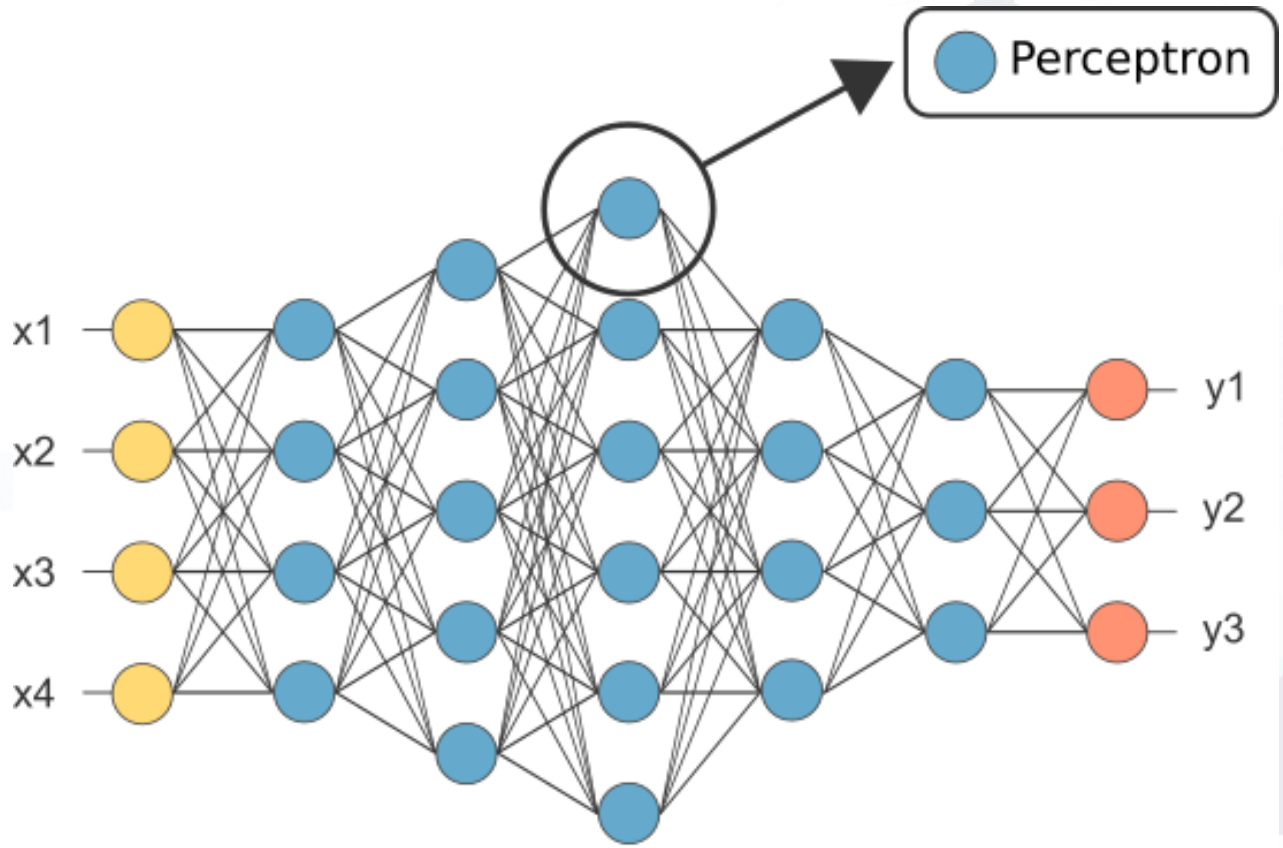

Rede Perceptron – Correção de Pesos

- Para o perceptron responder corretamente, deve ter os pesos “ideais”;
- Após a correção dos pesos, o neurônio emite resposta correta para qualquer nova entrada;
- Para obter esses pesos, no perceptron, utiliza-se um ajuste de peso, por meio da Regra Delta;

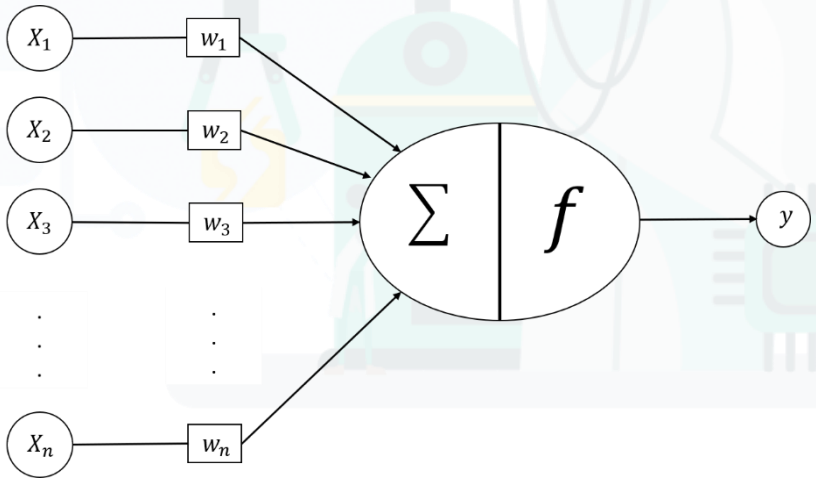

Rede Perceptron – Correção de Pesos

- Define-se aleatoriamente os pesos iniciais;

- Algoritmo baseado no erro

$$e = y - y_{pred}$$

  - Onde y_{pred} é a resposta emitida pelo perceptron.

- Atualização dos pesos

$$w_{i+1} = w_i + (t * x_i * e)$$

  - Onde *t* é a taxa de aprendizagem.

Algoritmo de Treinamento

- Enquanto não atingir condição de parada:
  - Para cada Amostra de Treinamento x:
    - Calcular a saída com os pesos atuais para x;
    - Calcular o erro;
    - Para cada peso do perceptron:
      - Atualiza usando a regra Delta

Taxa de Aprendizagem

- Dita o “quanto” a rede vai aprender em uma correção de peso;
- Influencia no tempo de treinamento de uma rede neural;
- Geralmente varia entre 0.1 e 1.0;

$$w_{i+1} = w_i + (t * x_i * e)$$

Taxa de Aprendizagem

Taxa de Aprendizagem

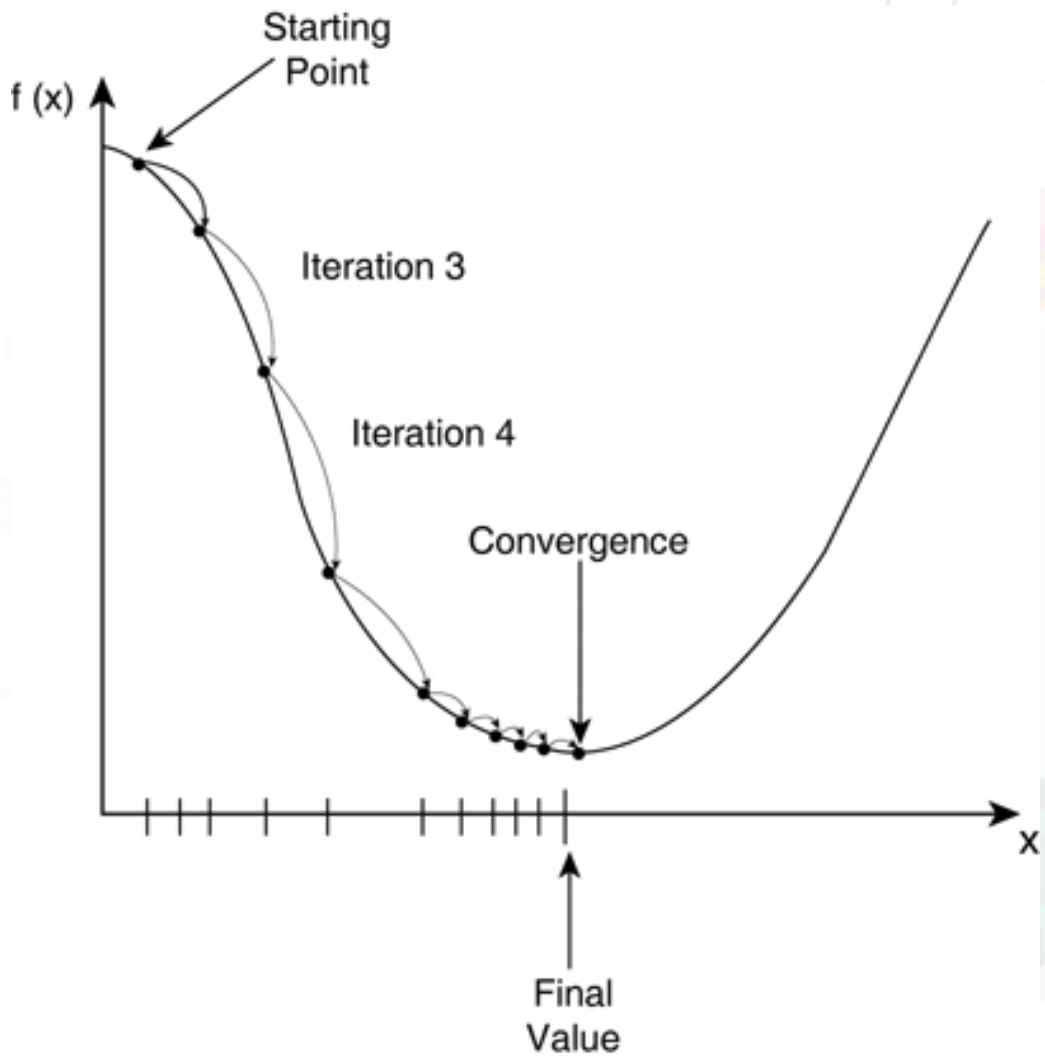

Taxa de Aprendizagem

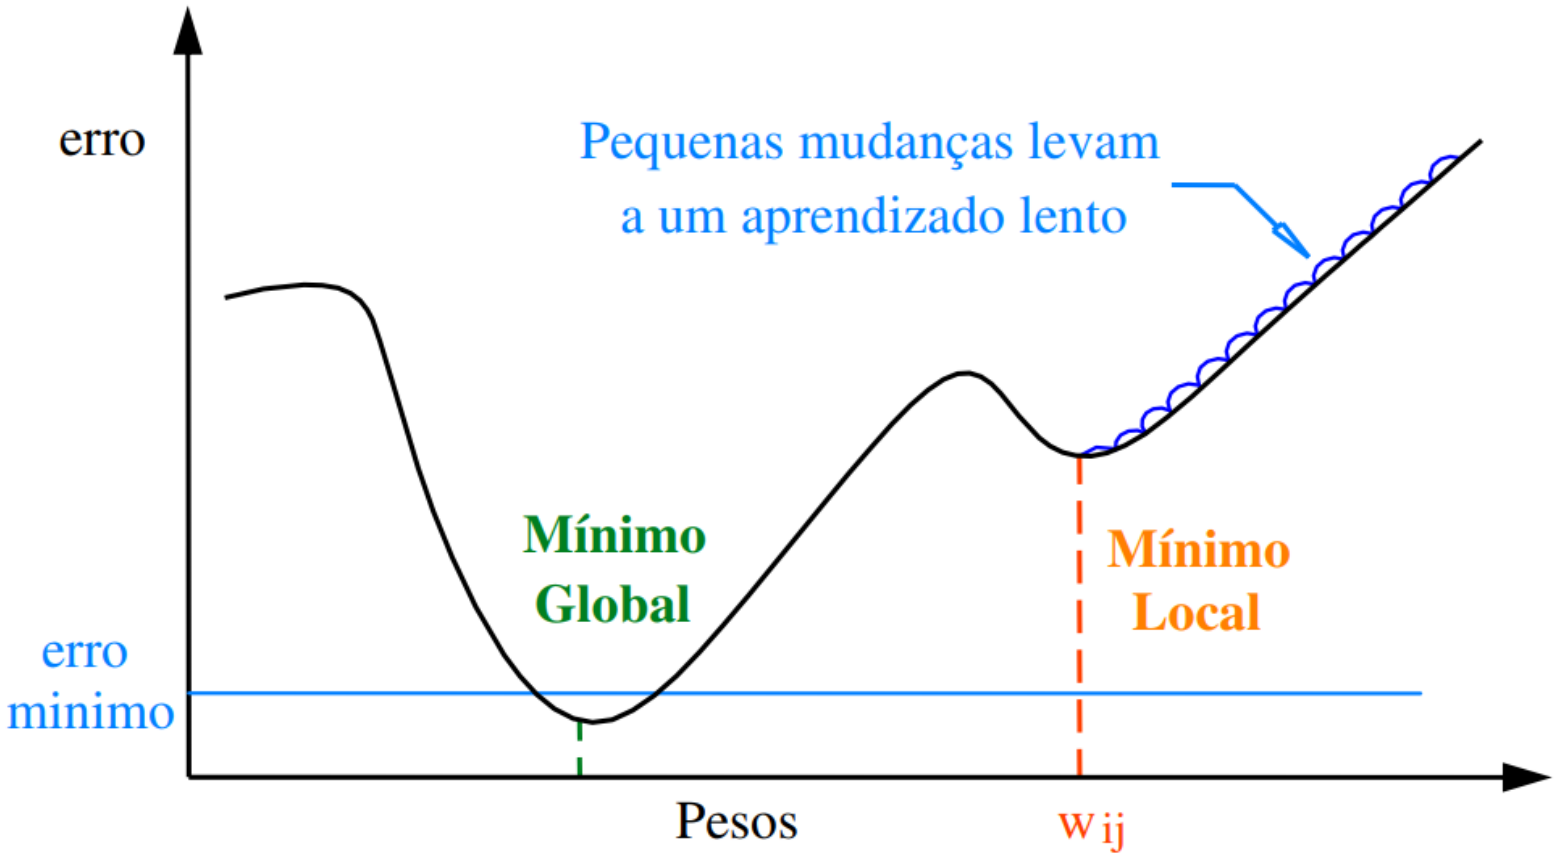

Taxa de Aprendizagem

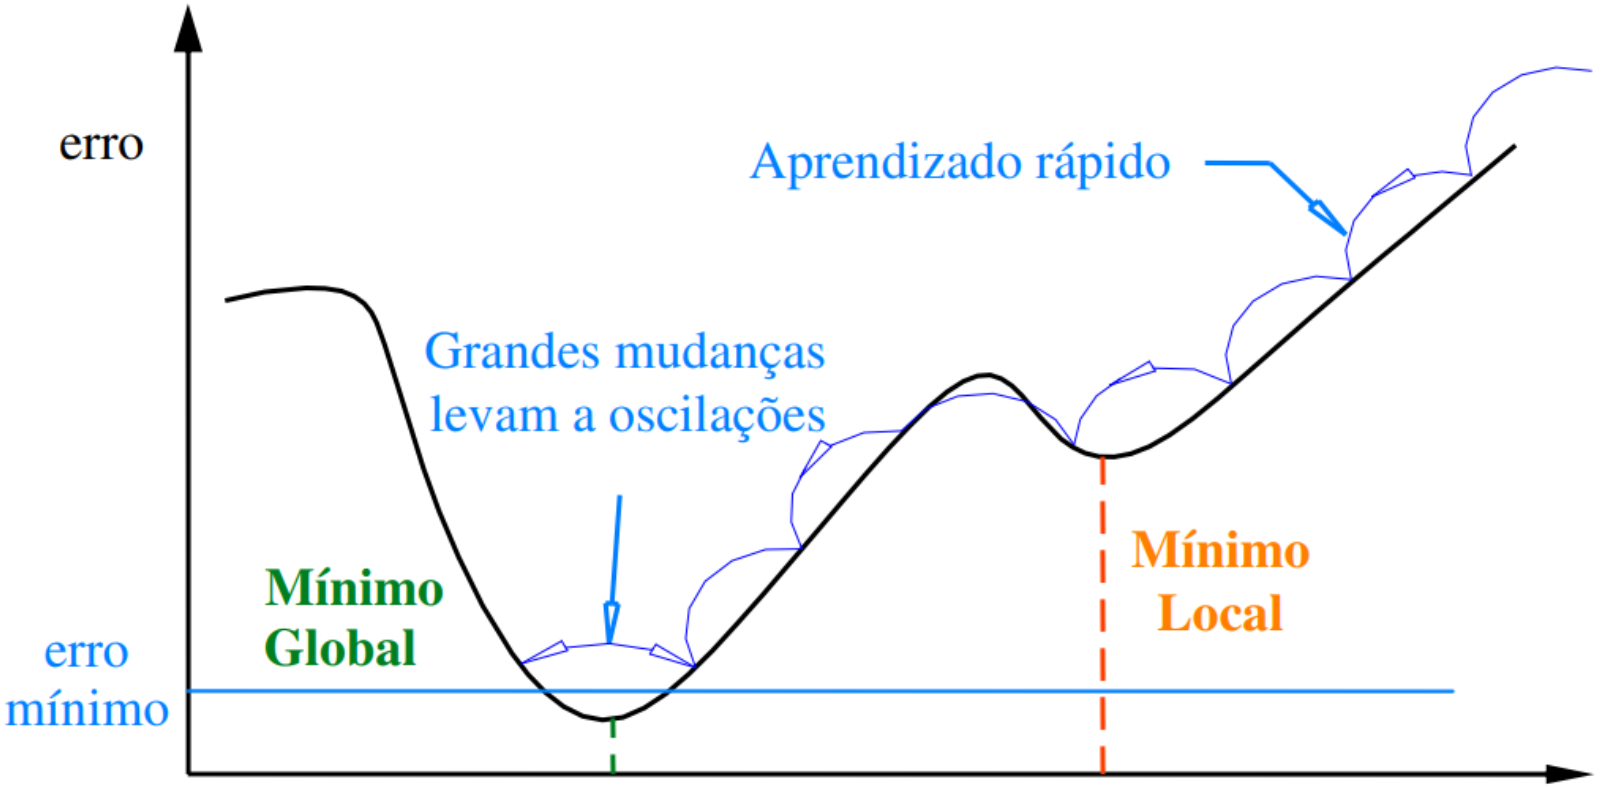

Rede Perceptron – Correção de Pesos

- Exemplo: Tabela Verdade OU

P	Q	P ou Q
V	V	V
V	F	V
F	V	V
F	F	F

X1	X2	Y
0	0	0
0	1	0
1	0	0
1	1	1

Rede Perceptron – Correção de Pesos

- Inicialização do Perceptron

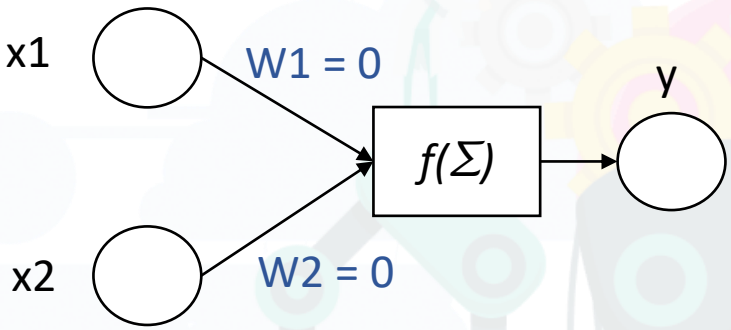

Pesos Iniciais

$$w1 = 0$$
$$w2 = 0$$

Função de Ativação

$$f(x) = \begin{cases} 0, x < 1 \\ 1, x \geq 1 \end{cases}$$

Rede Perceptron – Correção de Pesos

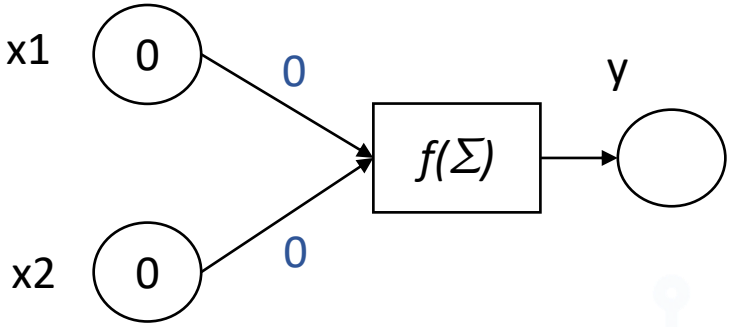

$$0 * 0 + 0 * 0 = 0$$

$$f(0) = 0$$

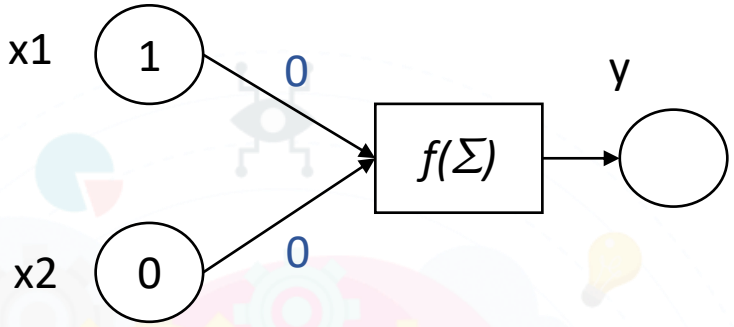

$$1 * 0 + 0 * 0 = 0$$

$$f(0) = 0$$

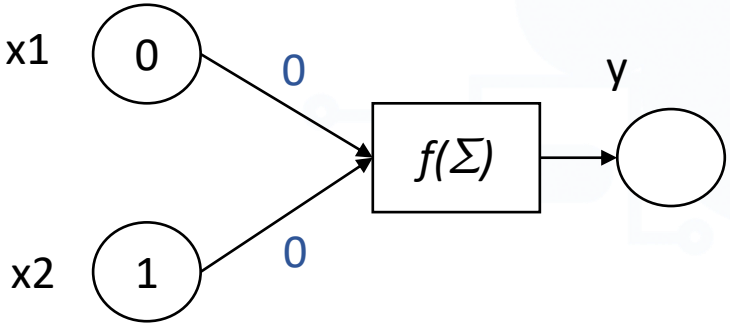

$$0 * 0 + 1 * 0 = 0$$

$$f(0) = 0$$

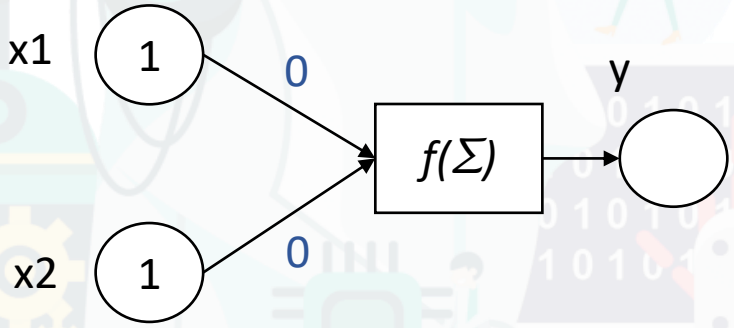

$$1 * 0 + 1 * 0 = 0$$

$$f(0) = 0$$

Rede Perceptron – Correção de Pesos

X1	X2	Y	Y_pred	Erro
0	0	0	0	0 – 0 = 0
0	1	0	0	0 – 0 = 0
1	0	0	0	0 – 0 = 0
1	1	1	0	1 – 0 = 1

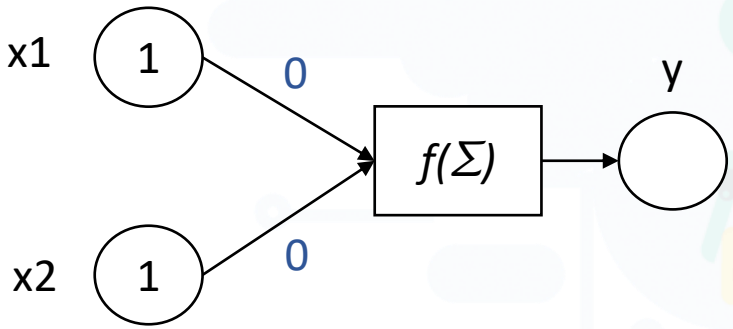

$$1 * 0 + 1 * 0 = 0$$

$$f(0) = 0$$

$$w_{i+1} = w_i + (t * x_i * e)$$

$$w_1 = 0 + (0.1 * 1 * 1) = 0.1$$

$$w_2 = 0 + (0.1 * 1 * 1) = 0.1$$

Rede Perceptron – Correção de Pesos

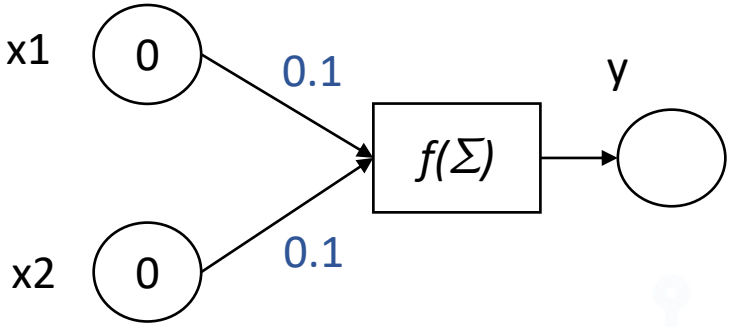

$$0 * 0.1 + 0 * 0.1 = 0$$

$$f(0) = 0$$

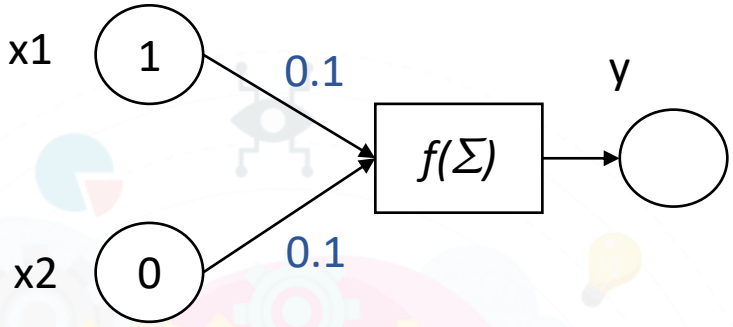

$$1 * 0.1 + 0 * 0.1 = 0.1$$

$$f(0.1) = 0$$

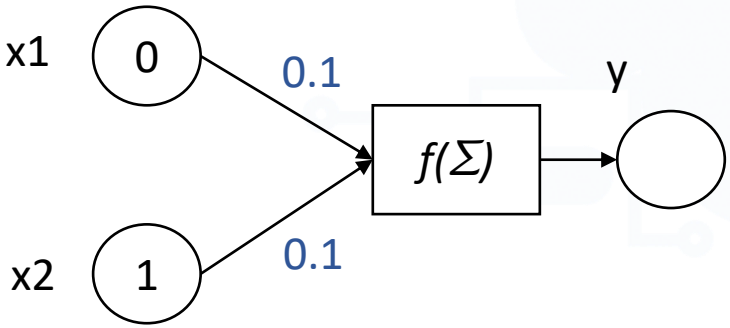

$$0 * 0.1 + 1 * 0.1 = 0.1$$

$$f(0.1) = 0$$

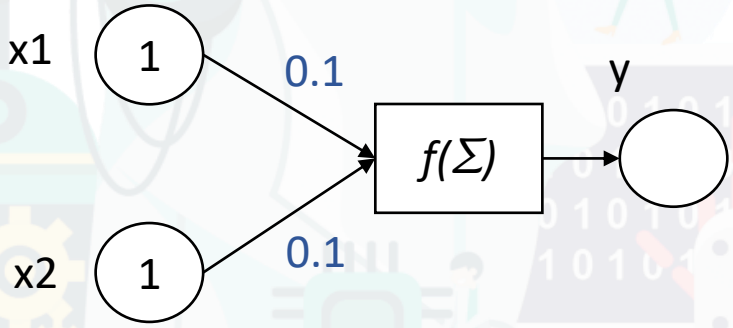

$$1 * 0.1 + 1 * 0.1 = 0.2$$

$$f(0.2) = 0$$

Rede Perceptron – Correção de Pesos

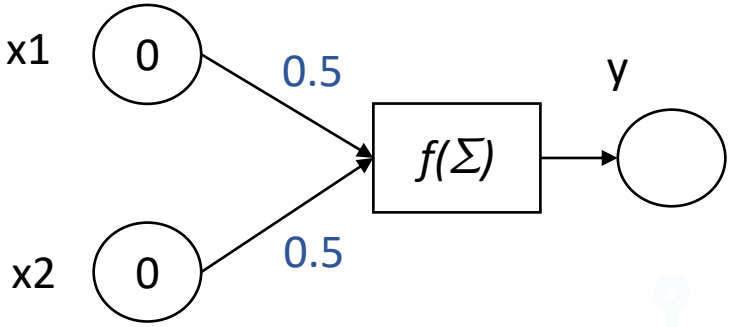

$$0 * 0.5 + 0 * 0.5 = 0$$

$$f(0) = 0$$

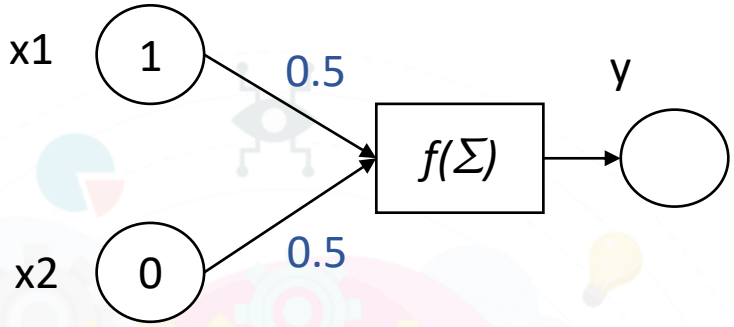

$$1 * 0.5 + 0 * 0.5 = 0.5$$

$$f(0.1) = 0$$

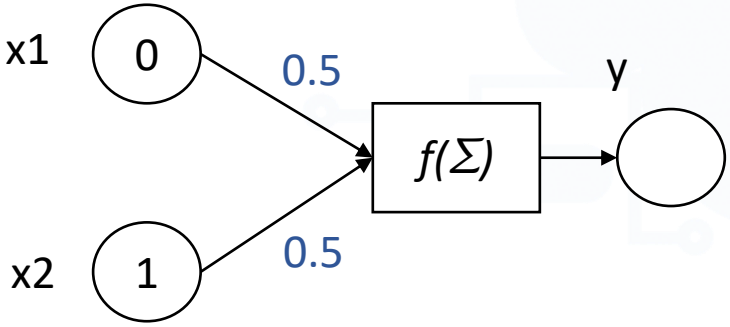

$$0 * 0.5 + 1 * 0.5 = 0.5$$

$$f(0.5) = 0$$

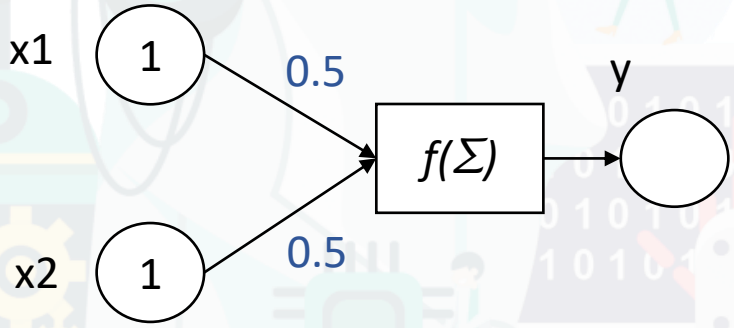

$$1 * 0.5 + 1 * 0.5 = 1$$

$$f(1) = 1$$

Treinamento Perceptron

- Treinar um perceptron significa ajustar os pesos para que este responda corretamente para todas as entradas;

- Os pesos iniciais influenciam no tempo de treinamento;

Implementação

- Hora de Prática
  - Implementação de um neurônio artificial em Python.

P	Q	P ou Q
V	V	V
V	F	V
F	V	V
F	F	F

X1	X2	Y
0	0	0
0	1	0
1	0	0
1	1	1

Rede Perceptron

- Pode conter mais de um neurônio;
- Resolve apenas problemas lineares

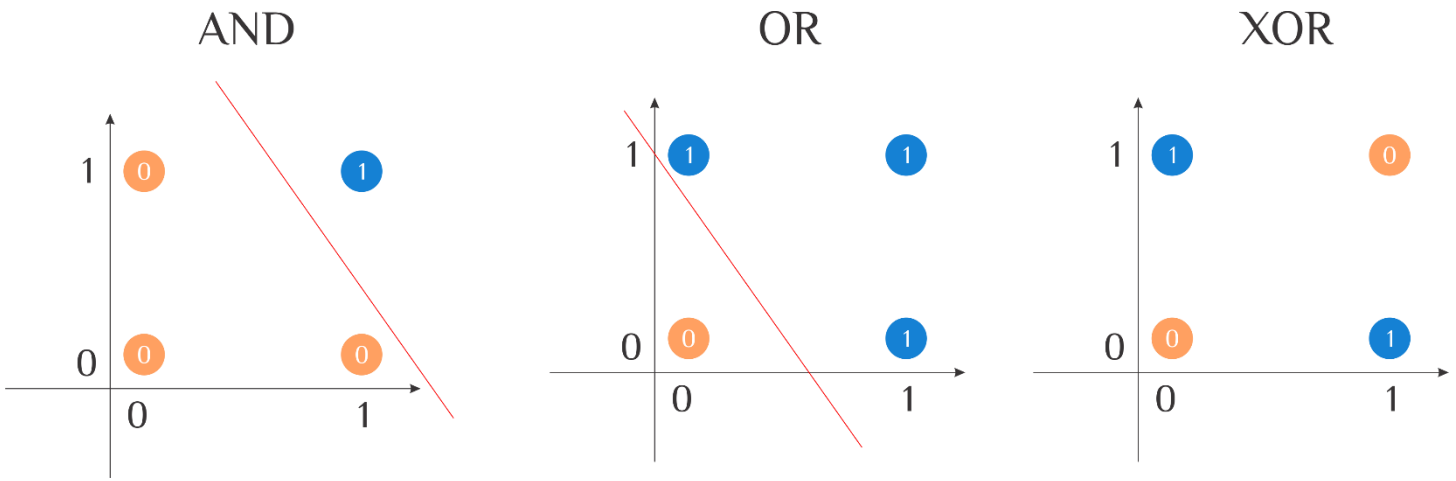

Funções de Ativação

- São essenciais para dar capacidade representativa às redes neurais artificiais;
- Introduz componente de não linearidade à rede;
- Decide a ativação ou não de um neurônio.

Funções de Ativação

- Considere a Equação:

$$y = f(x_1 w_1 + x_2 w_2 + x_3 w_3)$$

- Removendo a função *f:*

$$y = x_1 w_1 + x_2 w_2 + x_3 w_3$$

- *Resta apenas um modelo de regressão linear*

Funções de Ativação

- Função Degrau

$$f(x) = \begin{cases} 1, x > 0 \\ 0, x < 0 \end{cases}$$

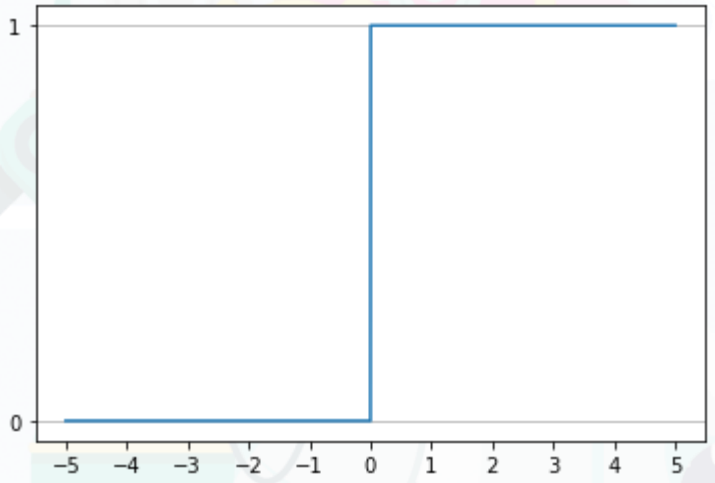

Funções de Ativação

- Função Sigmoide

$$f(x) = \frac{1}{1+ e^{-x}}$$

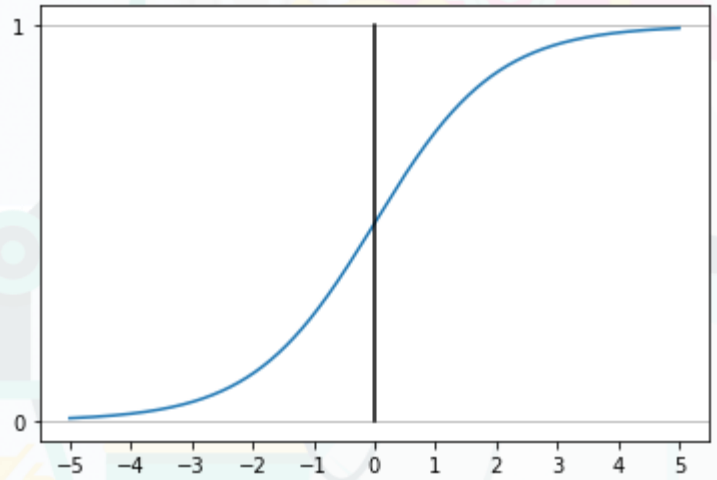

Funções de Ativação

- Função Tangente Hiperbólica

$$f(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

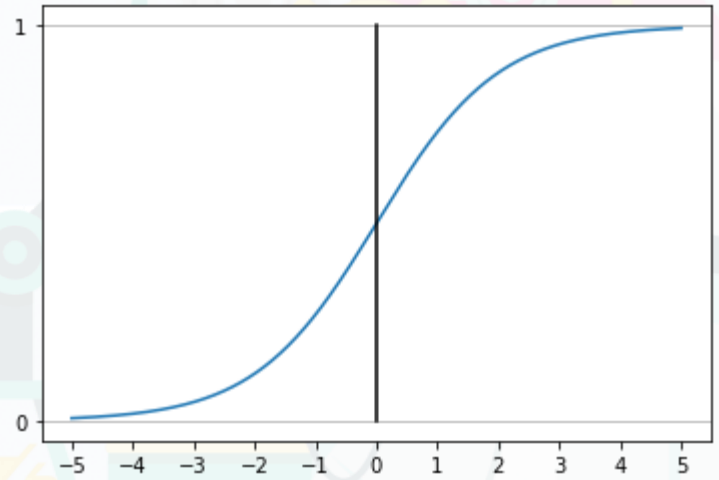

Funções de Ativação

- Função Tangente Hiperbólica

$$f(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

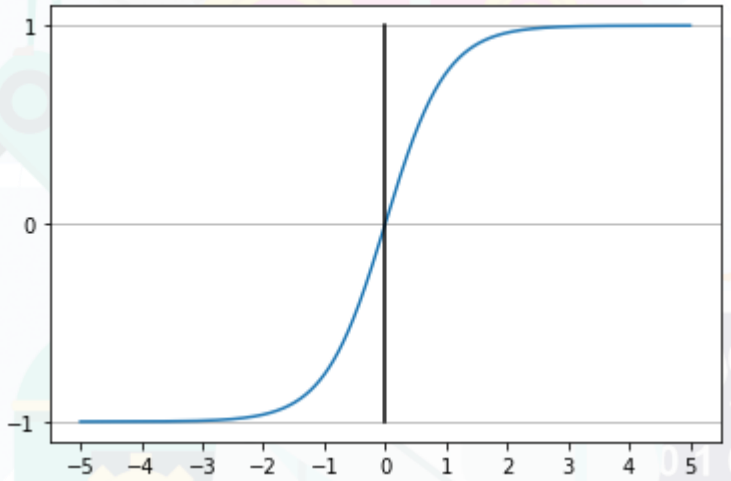

Funções de Ativação

- Função Relu

$$f(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

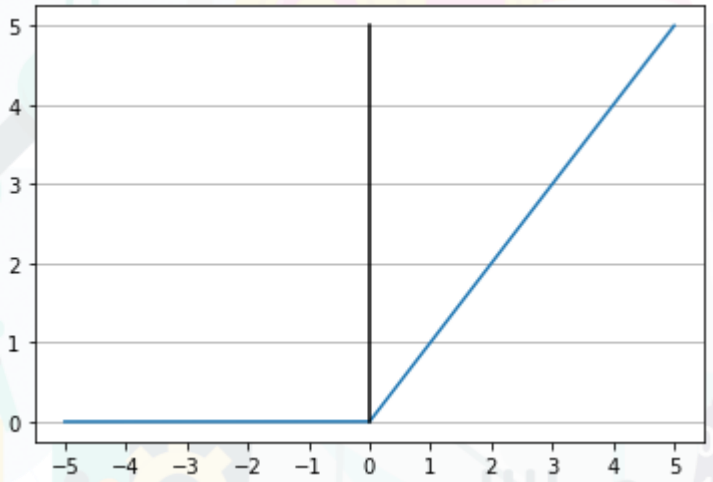

Funções de Ativação

- Função Softmax

$$f(x) = \frac{e^x}{\sum_i^n e^{x_i}}$$

- Utilizada na camada de saída.

Bias

- Também chamada viés ou limiar;
- O Bias permite flexibilidade de ajuste da RNA;
- Valor do bias varia entre -1 ou 1;
- Possui um peso associado que também é ajustado no treinamento.

Bias

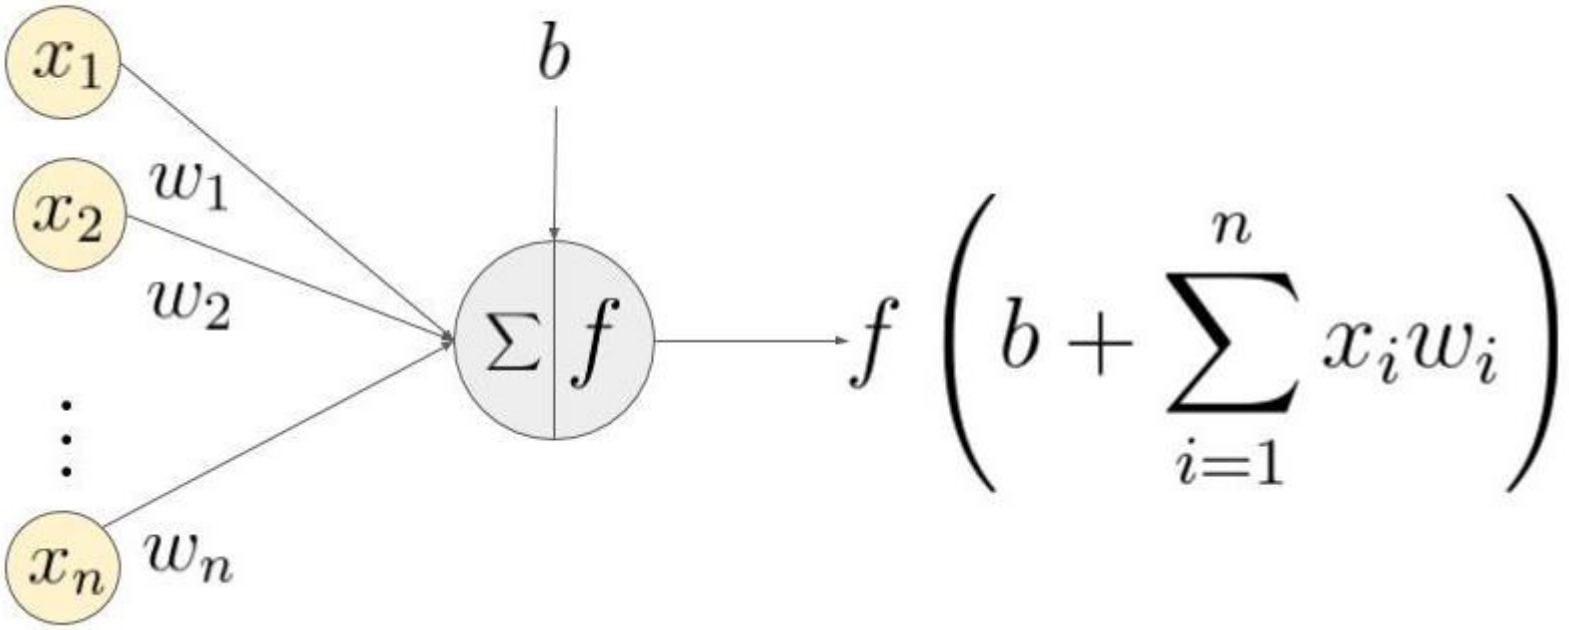

Bias

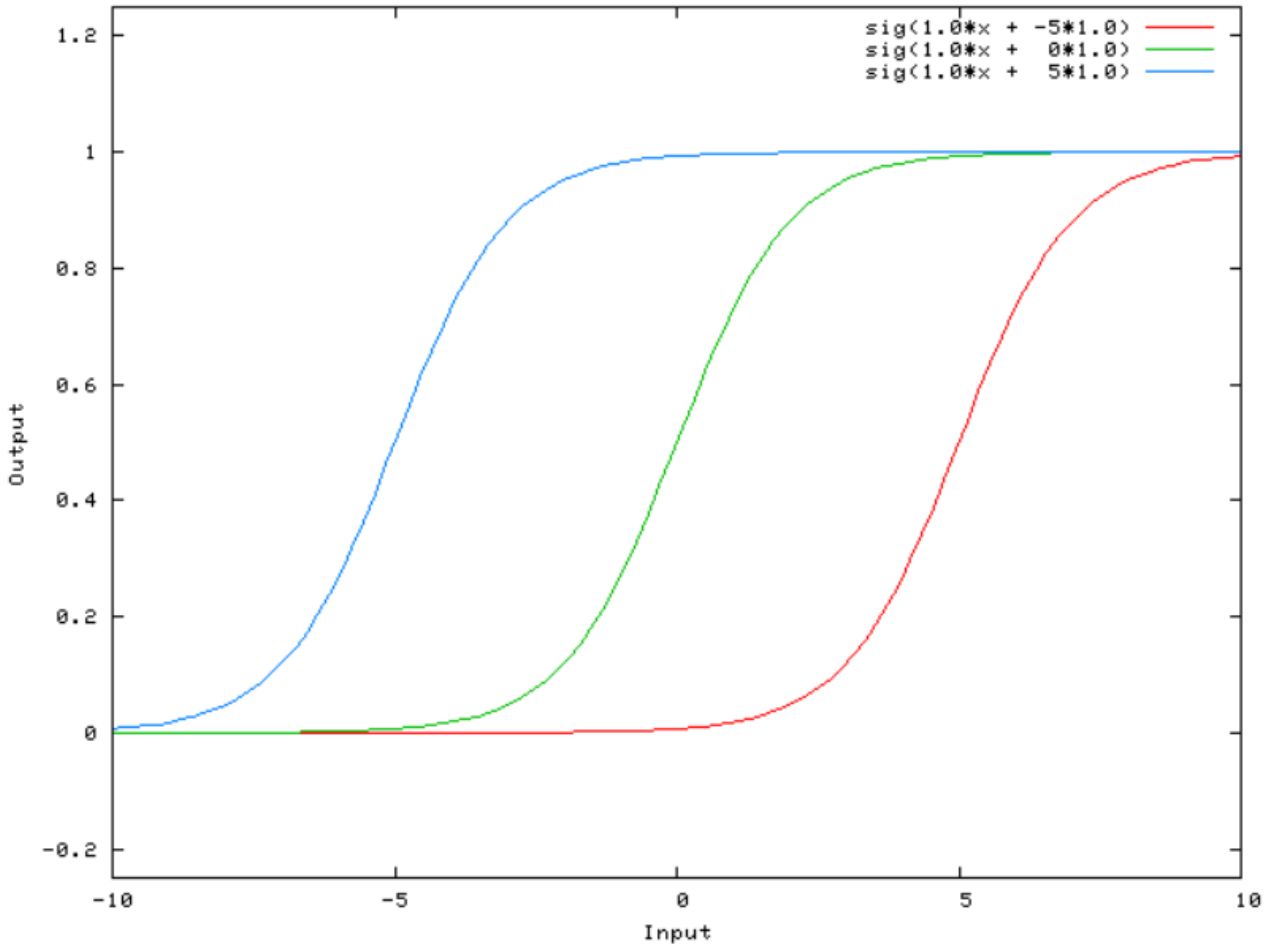
sig(1.0*x + -5*1.0)
sig(1.0*x + 0*1.0)
sig(1.0*x + 5*1.0)
Output
Input
1.2
1
0.8
0.6
0.4
0.2
0
-0.2
-10
-5
0
5
10

Rede Perceptron Multicamada

- Arquitetura onde os neurônios são organizados em pelo menos uma camada de entrada, uma camada oculta e uma camada de saída;

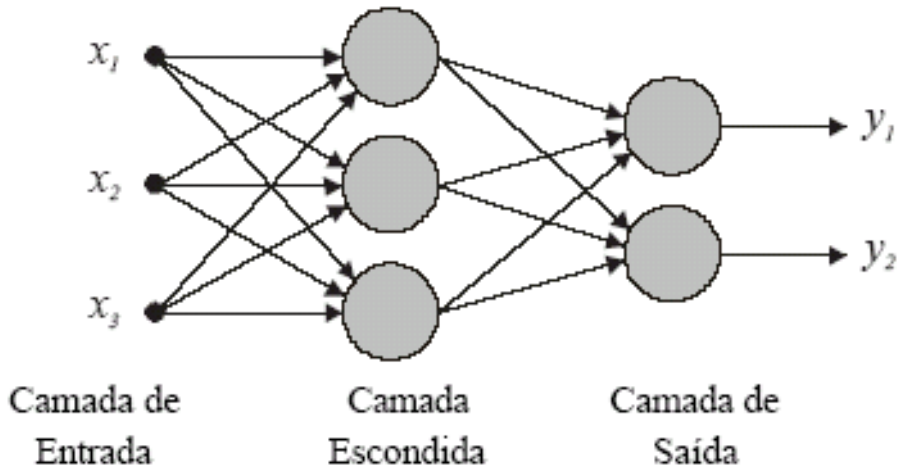

Rede Perceptron Multicamada

- Arquitetura *feedforwad;*
- As limitações do perceptron deixam de existir;
- Aprendizado supervisionado e não supervisionado;
- Pode ser Rasa ou Profunda;

Treinamento de uma MLP

- Significa Ajuste dos pesos (parâmetros) da rede;
- Algoritmo *Backpropagation*;
- Alguns **hiperparâmetros** são determinados por tentativa e erro:
  - Configuração da Rede
  - Taxa de Aprendizado
  - Momentum
  - Tamanho do Lote

Algoritmo BackPropagation

Realiza o treinamento de uma Rede Neural Artificial;

O objetivo do backpropagation é otimizar os pesos para que a rede neural possa aprender a mapear corretamente as entradas para as saídas.

Algoritmo Backpropagation

- “Retropropagação do Erro”;
- Corrige os erros da uma MLP por meio da descida do gradiente;
- Realizado em duas fases:
  - Forwad - Propagação
  - Backforwad - Retropropagação

Algoritmo Backpropagation

- Fase Forward

$$a_1 = f_1(x_1 w_1 + x_2 w_4)$$
$$a_2 = f_2(x_1 w_2 + x_2 w_5)$$
$$a_3 = f_3(x_1 w_3 + x_2 w_6)$$
$$a_4 = f_4(a_1 w_7 + a_2 w_9 + a_3 w_{11})$$
$$a_5 = f_4(a_1 w_8 + a_2 w_{10} + a_3 w_{12})$$

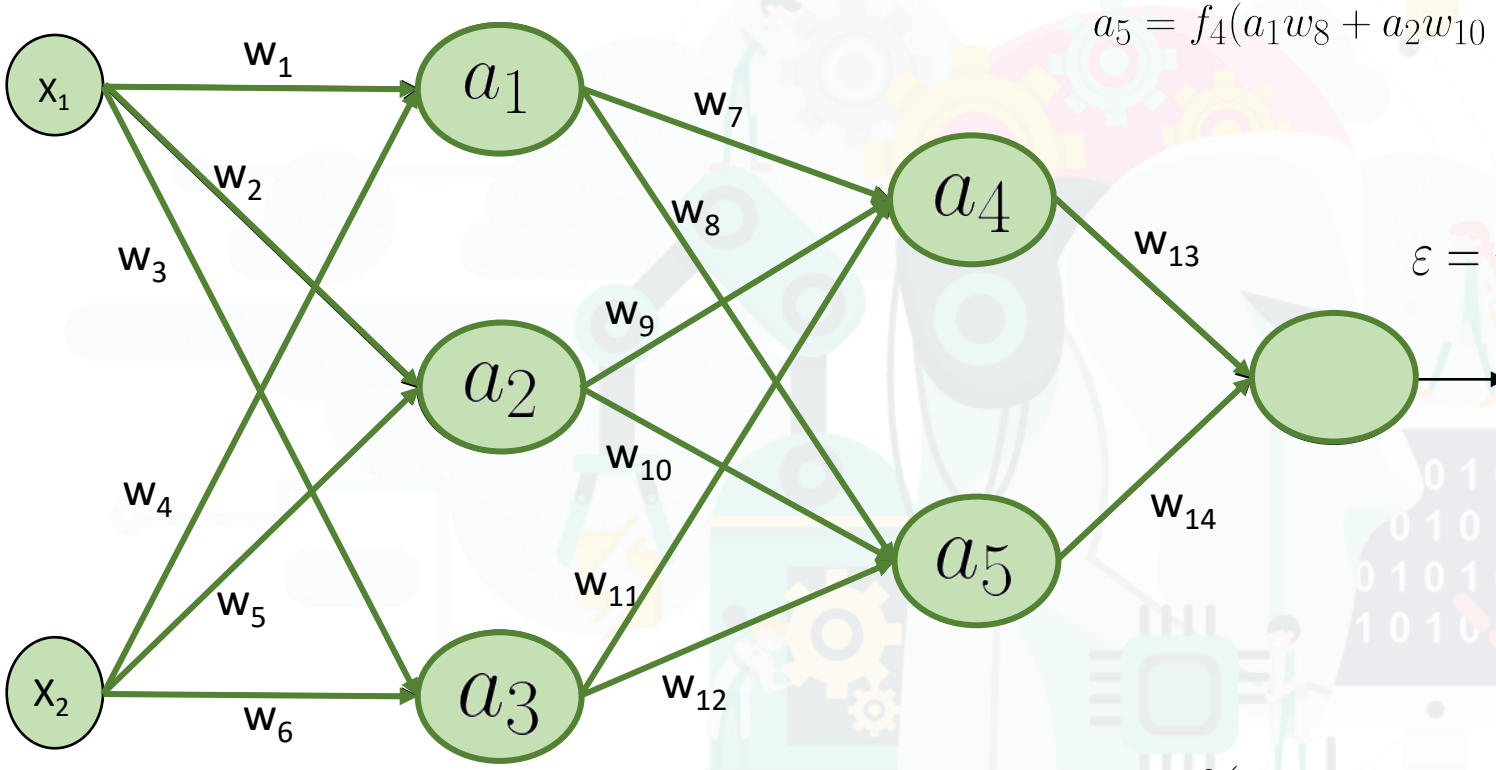

$$\varepsilon = y^s - y$$

$$y = f(a_4 w_{13} + a_5 w_{14})$$

Algoritmo Backpropagation

- Fase Backward

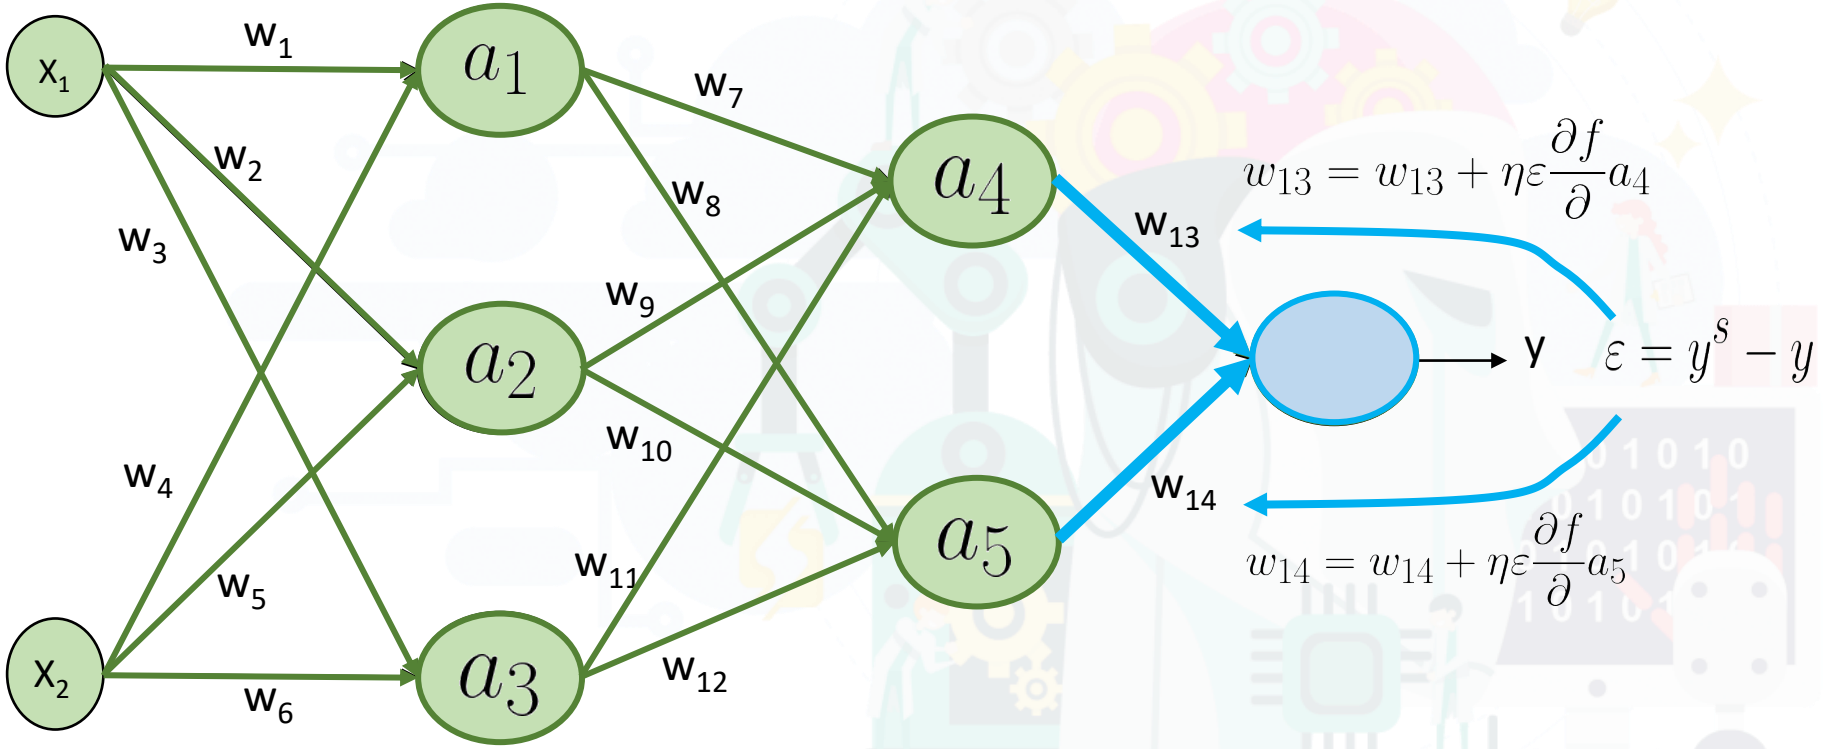

Algoritmo Backpropagation

- Fase Backward

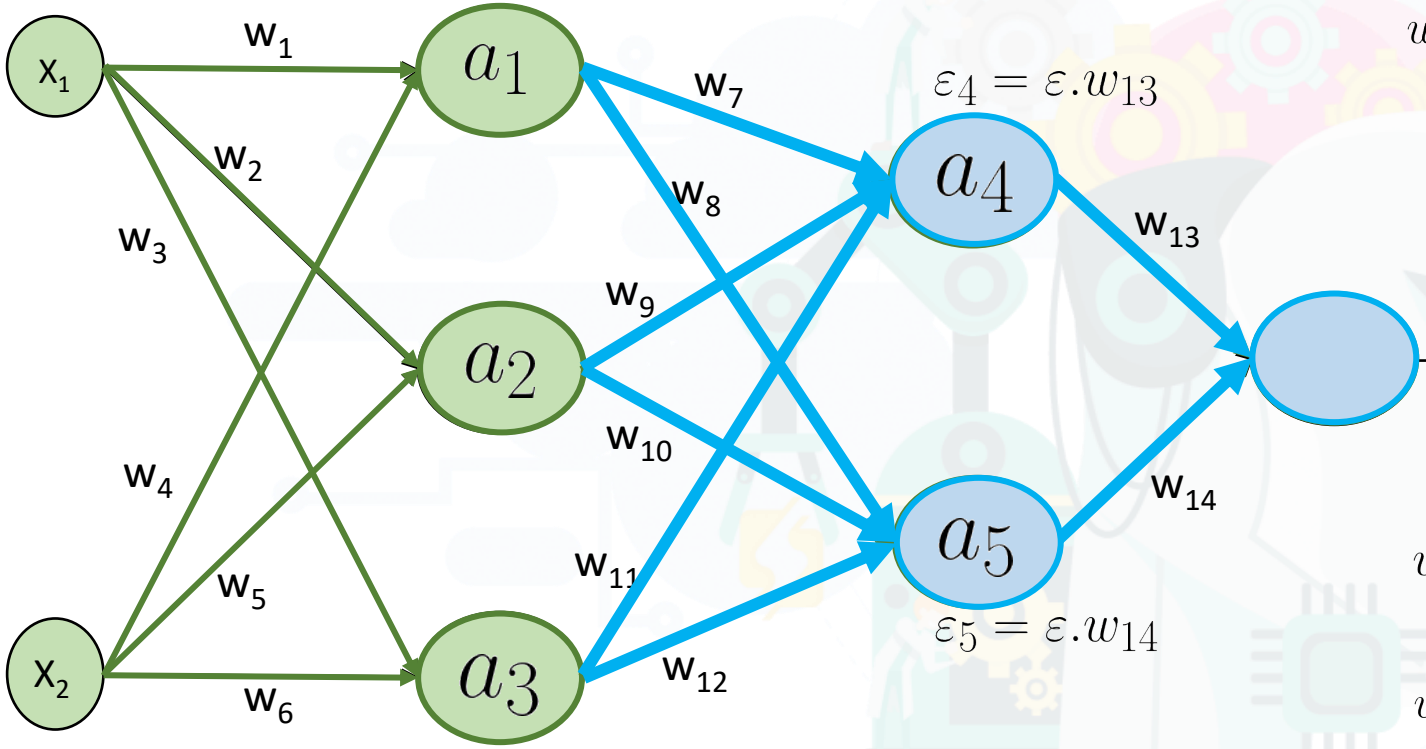

$$\varepsilon_4 = \varepsilon . w_{13}$$

$$\varepsilon_5 = \varepsilon . w_{14}$$

$$\varepsilon = y^s - y$$

$$w_7 = w_7 + \eta \varepsilon_4 \frac{\partial f}{\partial} a_1$$

$$w_9 = w_9 + \eta \varepsilon_4 \frac{\partial f}{\partial} a_2$$

$$w_{11} = w_{11} + \eta \varepsilon_4 \frac{\partial f}{\partial} a_3$$

$$w_8 = w_8 + \eta \varepsilon_5 \frac{\partial f}{\partial} a_1$$

$$w_{10} = w_{10} + \eta \varepsilon_5 \frac{\partial f}{\partial} a_2$$

$$w_{12} = w_{12} + \eta \varepsilon_5 \frac{\partial f}{\partial} a_3$$

Algoritmo Backpropagation

- Fase Backward

$$\varepsilon_1 = \varepsilon_4.w_7 + \varepsilon_5.w_8$$
$$\varepsilon_2 = \varepsilon_4.w_9 + \varepsilon_5.w_{10}$$
$$\varepsilon_3 = \varepsilon_4.w_{11} + \varepsilon_5.w_{12}$$

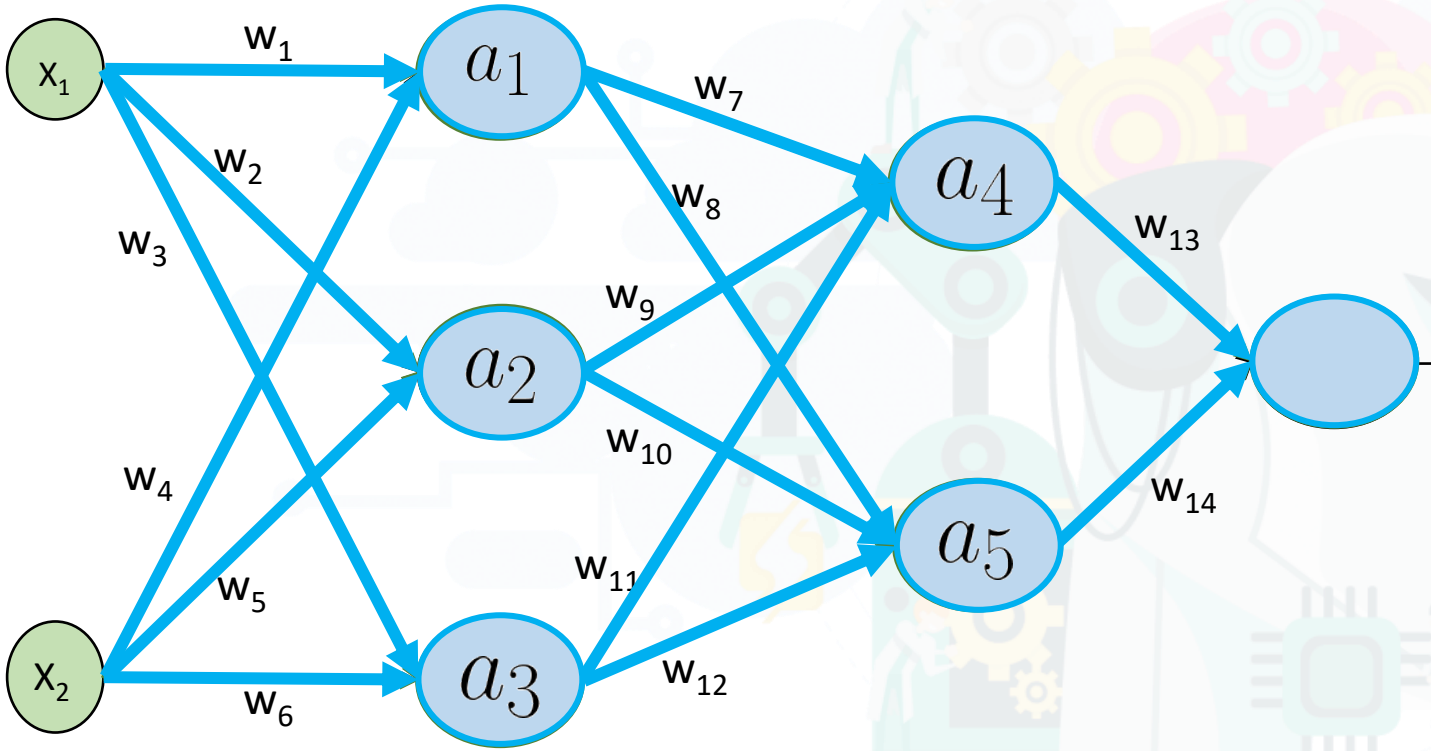

$$w_1 = w_1 + \eta\varepsilon_1\frac{\partial f}{\partial}x_1$$
$$w_2 = w_2 + \eta\varepsilon_2\frac{\partial f}{\partial}x_1$$
$$w_3 = w_3 + \eta\varepsilon_3\frac{\partial f}{\partial}x_1$$

$$\varepsilon = y^s - y$$

$$w_4 = w_4 + \eta\varepsilon_1\frac{\partial f}{\partial}x_2$$
$$w_5 = w_5 + \eta\varepsilon_2\frac{\partial f}{\partial}x_2$$
$$w_6 = w_6 + \eta\varepsilon_3\frac{\partial f}{\partial}x_2$$

Algoritmo Backpropagation

- Por X épocas:
- Passo 1 – Inicialização dos Pesos e Hiperparâmetros;
- Passo 2 - Fase Forward
  - Para cada entrada X, calcular a saída y;
  - Calcular o erro da saída da rede
- Passo 3 – Fase backward
  - Efetuar os cálculos de atualização dos Pesos da rede da camada saída até chegar a camada de entrada.

Algoritmo BackPropagation

- As fases forward e backward são realizadas para todas as amostras de entrada do conjunto de treino;

- Condições de Parada:
  - Erro aceitável;
  - Quantidade de épocas

- **Época** – Quando processo de forward e backward realizado com todas as entradas é caracterizado uma época.

Algoritmo Backpropagation

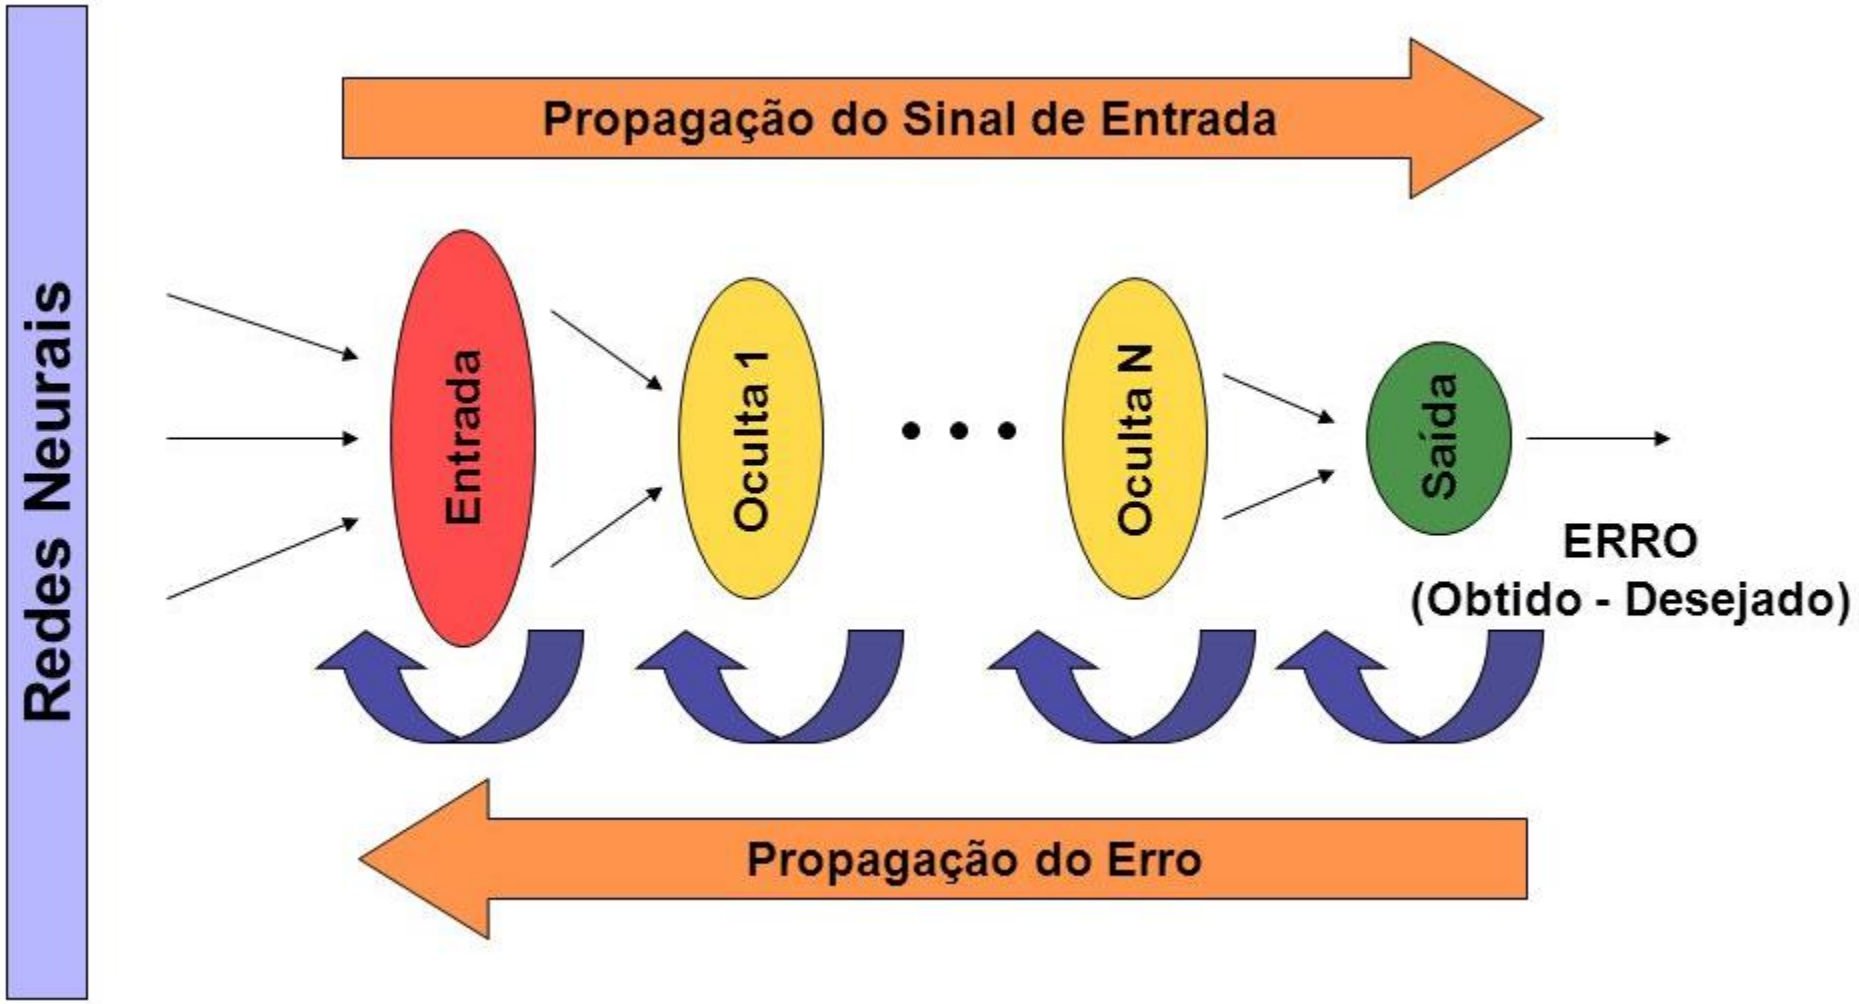

Universidade Federal do Piauí
Laboratório de Inteligência Artificial - LINA

Introdução à Deep Learning

Bruno Vicente Alves de Lima